System zur Segmentierung einer Dart-Scheibe

Studienarbeit

des Studiengangs Informatik

an der DHBW Stuttgart Campus Horb

von

Din Alomerovic

25. April 2026

Bearbeitungszeitraum	12 Wochen
Matrikelnummer, Kurs	1234567, INF20xx
Betreuer	Philipp Kremling

Ehrenwörtliche Erklärung

Ich versichere hiermit, dass ich meine Arbeit mit dem Thema *System zur Segmentierung einer Dart-Scheibe* selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe.

Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Ich habe bei der Erstellung der Arbeit KI-Werkzeuge eingesetzt. Dies habe ich an den entsprechenden Stellen der Arbeit kenntlich gemacht.

ORT, DATUM

AUTOR

Abstract

HIER IST MEINE ZUSAMMENFASSUNG

Inhaltsverzeichnis

Abkürzungsverzeichnis **IV**

Abbildungsverzeichnis **V**

Tabellenverzeichnis **VI**

Listings **VII**

1 Einleitung **1**

2 Theoretische Grundlagen **4**
2.1 Canny-Kantendetektion 4
2.2 Hough Transformation 5
2.3 Homographie 6
2.4 Homogene Koordinaten 7
2.5 Convolutional Neural Networks (CNNs) 7
2.6 U-Net Architektur 7
2.7 Evaluationsmetriken 7

3 Methodik **8**
3.1 Algorithmischer Ansatz 8
3.1.1 Vorverarbeitung 9
3.1.2 Erkennung der Dartscheibe im Bild 9
3.1.3 Perspektivische Korrektur und Normalisierung 10
3.1.4 Lokalisierung der Ringe 11
3.1.5 Lokalisierung der Segmentlinien 12
3.1.6 Berechnung des Scores 12
3.2 Machine Learning Ansatz 12
3.3 Evaluation 12

4 Ergebnisse **13**

5 Fazit und Ausblick **14**

Literatur **15**

Anhang **17**

Abkürzungsverzeichnis

HT Hough Transformation

Abbildungsverzeichnis

2.1 Grundprinzip der Hough-Transformation 5
2.2 Parameterraum in Polarkoordinaten 6

3.1 Übersicht über die algorithmische Pipeline 9

Tabellenverzeichnis

2.1 Accumulator-Array im Parameterraum (m, c) 6

3.1 Suchbereiche der Hough-Kreiserkennung je Ring im normierten 1024×1024-Koordinatensystem. 11

Listings

1 Einleitung

Beim Dartspielen stellt das manuelle Zählen der Punkte für viele Hobbyspielerinnen und Hobbyspieler weiterhin eine zentrale Hürde dar, da es als zeitaufwändig, fehleranfällig und wenig intuitiv empfunden wird. Zwar existieren digitale Alternativen wie etwa elektronische Dartscheiben, doch bevorzugen viele Spielerinnen und Spieler weiterhin klassische Boards mit echten Pfeilen. Daraus erwächst der Wunsch nach einer Lösung, die das Punktezählen kontaktlos und ohne zusätzliches Equipment ermöglicht - idealerweise allein basierend auf einem Smartphone-Foto.

Für eine präzise, automatisierte Score-Ermittlung ist die zuverlässige digitale Repräsentation der Dartscheibenstruktur eine grundlegende Voraussetzung. Damit die geworfenen Punkte eindeutig den entsprechenden Feldern zugeordnet werden können, muss die Dartscheibe in einem aufgenommenen Bild robust erkannt, perspektivisch korrigiert und geometrisch segmentiert werden. Dieser Prozess ist wesentlicher Bestandteil der Bildverarbeitungspipeline und bildet die algorithmische Grundlage für sämtliche nachgelagerten Analyse- und Klassifikationsschritte.

Die technische Umsetzung dieser Segmentierung birgt jedoch mehrere Herausforderungen. Die klassische Dartscheibe, weist aufgrund ihrer ringförmigen Struktur, kontrastintensiven Farbfelder, feinen Segmentlinien sowie metallischer oder faserbasierter Materialien eine komplexe Erscheinung auf. Variierende Kamerawinkel erzeugen projektive Verzerrungen, die ohne geeignete Transformation zu fehlerhaften Feldzuordnungen führen würden. Zusätzlich erschweren wechselnde Lichtbedingungen, Reflexionen der Metall-Score-Ringe, Verdeckungen durch bereits steckende Dartpfeile, schlechter Zustand der Scheibe durch intensive Nutzung sowie unterschiedliche Hintergründe das Erkennen der einzelnen Konturen einer Dartscheibe.

Zur Lösung dieser Problematik stehen einerseits klassische, algorithmische Verfahren der Bildverarbeitung zur Verfügung - etwa Hough-Transformationen zur Kreis-Detektion, Canny-Edge-Filtering zur Kantenerkennung oder homographiebasierte Perspektivkorrekturen. Andererseits existieren moderne Deep-Learning-Ansätze, die mittels neuronaler Netze und semantischer Segmentierung (z. B. über architekturen wie U-Net oder Vision-Transformer-basierte Modelle) eine lernbasierte Erkennung ermöglichen. Ein Schwerpunkt dieser Studienarbeit besteht darin, die Ansätze hinsichtlich Robustheit, Erkennungsgenauigkeit, Implementierungsaufwand und Verarbeitungsgeschwindigkeit systematisch zu vergleichen.

Da die Bildaufnahme durch die Nutzerinnen und Nutzer nicht standardisiert erfolgt, unterscheiden sich die Fotos je nach Standpunkt, Distanz und Kamerawinkel teils erheblich voneinander. Die Position der fotografierenden Person variiert von Aufnahme zu Aufnahme, wodurch die Dartscheibe im Bild unterschiedlich groß erscheint und projektive Verzerrungen entstehen. Eine robuste Lösung muss daher unabhängig von festen Aufnahmepositionen funktionieren und in der Lage sein, perspektivische Abweichungen zuverlässig zu normalisieren. Diese Problematik stellt eine zusätzliche Herausforderung dar, da klassische regelbasierte Verfahren häufig feste geometrische Annahmen treffen, während lernbasierte Ansätze genügend Generalisierung für freie Aufnahmesituationen benötigen.

Ziel dieser Studienarbeit ist die Entwicklung und Evaluation eines robusten, ausschließlich auf Smartphone-Fotos basierenden Verfahrens zur zuverlässigen Dartboard-Erkennung, perspektivischen Normalisierung und geometrisch exakten Segmentierung klassischer Dartscheiben. Das Verfahren soll insbesondere unabhängig von der Position der Aufnahme, skalierungsinvariant und fehlertolerant gegenüber realen Störfaktoren wie ungünstigen Lichtverhältnissen oder teilweisen Verdeckungen durch bereits steckende Pfeile funktionieren. Es bildet damit die essenzielle Grundlage für eine spätere, feldgenaue Punktzuordnung und automatisierte Score-Berechnung.

Der methodische Schwerpunkt der Arbeit liegt auf der Konzeption eines klassischen, algorithmischen Computer-Vision-Ansatzes, bei dem die Scheibenregion primär über eine Kreiserkennung mittels Hough-Transformation lokalisiert wird. Um die dafür relevanten Kanteninformationen zu extrahieren, wird das Eingangsfoto zunächst durch Canny-Edge-Filtering aufbereitet. Anschließend soll eine homographiebasierte Perspektivtransformation eine orthogonale Board-Draufsicht erzeugen, aus der die Feldgeometrie über ein mathematisch definiertes Dartboard-Modell (Ring- und Radialgitter) berechnet und in einzelne Scoring-Segmente überführt wird.

Neben dem klassischen Computer-Vision-Ansatz verfolgt die Arbeit das Ziel,einen lernbasierten Lokalisierungsansatz zu entwickeln und zu evaluieren. Hierfür soll ein U-Net-basiertes Deep-Learning-Modell eingesetzt werden, das die Dartscheibe semantisch im Bild segmentiert und ihre Position als Pixelmaske vorhersagt. Auf eine vollständige Feldsegmentierung mittels Deep Learning wird dabei bewusst verzichtet: Da alle Felder einer Dartscheibe nahezu identische visuelle Merkmale aufweisen und sich lediglich durch ihre geometrische Position unterscheiden, wäre ein solches Modell auf einen umfangreichen, sorgfältig annotierten Datensatz angewiesen, dessen Erstellung den Rahmen dieser Arbeit übersteigen würde. Stattdessen übernimmt das U-Net-Modell ausschließlich die grobe Lokalisierung der Scheibe im Bild, während die präzise Segmentierung der einzelnen Felder anschließend durch einen geometrisch-algorithmischen Ansatz auf Basis von Homogra-

phie und Kreisgeometrie erfolgt. Ein zentraler Gegenstand der Zielsetzung ist dabei der Vergleich dieses Hybridansatzes mit einer rein algorithmischen Pipeline, um Stärken und Schwächen beider Varianten hinsichtlich Robustheit, Genauigkeit und praktischer Eignung für den mobilen Einsatz zu bewerten.

Sollte im Projektverlauf noch Zeit verbleiben, wird zusätzlich eine prototypische Kopplung mit einer komplementären Arbeit angestrebt, die Dartpfeile im Bild erkennt und deren Position bestimmt. Die Kombination beider Verfahren ermöglicht perspektivisch die Realisierung einer vollständigen, automatisierten Score-Ermittlung als Basis für eine nutzerfreundliche Dart-Scoring-App, die das analoge Spielgefühl klassischer Boards mit digitaler Unterstützung verbindet.

Im Mittelpunkt dieser Arbeit steht die folgende übergeordnete Leitfrage:

> *Welcher Ansatz – algorithmisch oder KI-basiert – bietet für die Lokalisierung und Segmentierung einer Dartscheibe in mobilen Fotos die bessere Gesamtbalance zwischen Implementierungsaufwand, Erkennungsgenauigkeit, Robustheit gegenüber realen Aufnahmebedingungen und Verarbeitungsgeschwindigkeit auf mobilen Endgeräten?*

Zur Beantwortung dieser Leitfrage werden die folgenden untergeordneten Forschungsfragen untersucht:

- **Algorithmische Lokalisierung:** Wie robust und präzise lässt sich eine Dartscheibe in mobilen Fotos mittels Canny-Filterung und Hough-Kreiserkennung lokalisieren und anschließend per Homographie entzerren?
- **KI-basierte Lokalisierung:** Welche Erkennungsgenauigkeit erreicht ein U-Net-Modell bei der Lokalisierung von Dartscheiben unter variierenden Aufnahmebedingungen auf mobilen Endgeräten?
- **Hybridansatz:** Inwiefern verbessert eine vorgelagerte KI-basierte Lokalisierung die Genauigkeit der anschließenden algorithmischen Feldsegmentierung gegenüber einem rein algorithmischen Pipeline-Ansatz?
- **Robustheit und Störfaktoren:** Welche Aufnahmebedingungen – insbesondere Lichtverhältnisse, Perspektive, Skalierung und Verdeckungen – beeinträchtigen die Lokalisierungsgenauigkeit beider Ansätze am stärksten?

2 Theoretische Grundlagen

2.1 Canny-Kantendetektion

Der Canny-Kantendetektor, vorgestellt von John Canny 1986 [Can86], ist ein mehrstufiger Algorithmus, der auf einer formalen Definition der Zielsetzung eines idealen Kantendetektors basiert. Er formulierte die Kantenerkennung als ein Optimierungsproblem. Er definierte drei mathematische Kriterien, die ein optimaler Detektor für stufenförmige Kanten erfüllen muss, und leitete daraus eine spezifische Operatorform ab. Der Algorithmus ist daher als eine direkte technische Umsetzung dieser Kriterien zu verstehen.

1. **Gute Erkennungrate:** Die Fehlerwahrscheinlichkeit, echte Kanten zu übersehen oder fälschlicherweise Nicht-Kanten zu markieren, muss minimiert werden.
2. **Gute Lokalisierung:** Die markierte Kantenposition soll eine minimale Abweichung vom tatsächlichen Kantenzentrum aufweisen.
3. **Eindeuige Antwort:** Der Detektor darf auf eine einzelne Kante nicht mit mehreren lokalen Maxima antworten.

Der Canny-Kantendetektor arbeitet in vier Schritten. Zunächst wird das Eingabebild durch Faltung mit einem zweidimensionalen Gauß-Filter geglättet, um hochfrequentes Rauschen zu unterdrücken. Die Standardabweichung σ des Filters ist dabei der zentrale freie Parameter: Ein größeres σ führt zu robusterer Erkennung auf Kosten der Lokalisierungsgenauigkeit feiner Kantenstrukturen. Im zweiten Schritt wird der Gradient des geglätteten Bildes durch Faltung mit der ersten Ableitung der Gauß-Funktion berechnet, woraus für jeden Pixel die Kantenstärke und Kantenrichtung bestimmt werden. Der dritte Schritt, die Nicht-Maxima-Unterdrückung (Non-Maximum Suppression), dünnt die Kantenantworten auf eine Pixelbreite aus, indem nur lokale Maxima entlang der Gradientenrichtung erhalten bleiben. Abschließend erfolgt eine Klassifikation mittels Hysterese-Schwellwertverfahren mit zwei Schwellwerten T_1 und T_2. Pixel oberhalb von T_1 gelten als sichere Kanten, Pixel zwischen T_2 und T_1 werden nur dann akzeptiert, wenn sie mit einer sicheren Kante räumlich verbunden sind. Dies verhindert das als *Streaking* bekannte Abreißen von Kantenzügen durch lokale Schwankungen der Kantenstärke.

2.2 Hough Transformation

Die Hough Transformation (HT) ist ein grundlegendes Verfahren der digitalen Bildverarbeitung und des maschinellen Sehens, das der Erkennung geometrischer Formen und Muster in Bilddaten dient. Sie wurde ursprünglich von Paul Hough im Jahr 1962 in einem Patent zur Erkennung komplexer Muster in Blasenkammeraufnahmen vorgestellt. [IK88; Hou62].

Die Funktionsweise der HT veranschaulicht die Abbildung 2.1. Dabei werden Punkte aus dem ursprünglichen Bildraum in den Parameterraum transformiert. Der Bildraum ist im klassischen Sinne der Raum in dem Punkte in x und y Koordinaten angegeben werden. Der Parameterraum bezieht sich hingegen auf die beiden Parameter m und c einer Geraden. Eine wichtige Eigenschaft hierbei ist, dass Punkte im Bildraum durch die Transformation zu Geraden im Parameterraum werden. Der Schnittpunkt der Geraden im Parameterraum gibt die Parameter m und c der Geraden an, durch die die jeweiligen Punte im Bildraum verbunden werden. [IK88]

Um die HT berechnen zu können, wird der Parameterraum als ein mehrdimensionales Array dargestellt, wobei jedes Element hochgezählt wird, sobald eine Gerade dadurch verläuft. Die Erkennung von Hochpunkten ist im Parameterraum einfacher und rechnerisch weniger fordernd als im Bildraum. [IK88] Die Tabelle 2.1 dient dafür als Veranschaulichung.

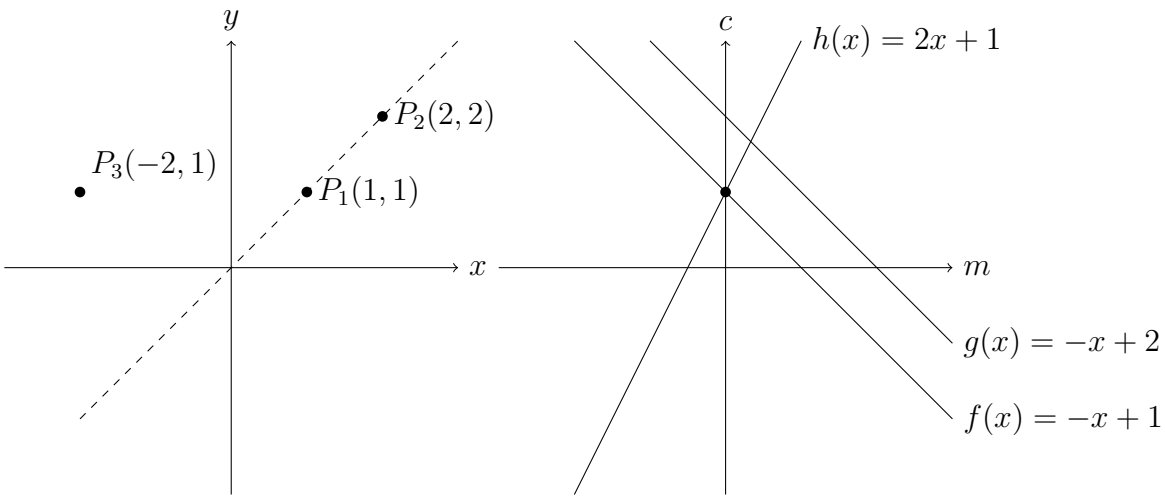

(a) Punkte im Bildraum (b) Punkte im Parameterraum

Abbildung 2.1: Grundprinzip der Hough-Transformation

In einer Veröffentlichung von Duda und Hart [DH72] wurde vorgeschlagen, dass man statt der ursprünglichen Geradenform mit m und c die Normalform welche durch folgende Gleichung beschrieben wird nutzt. Dabei gibt ρ den Abstand der Geraden zum Ursprung und θ den Winkel der Normalen zur Gerade im Intervall $[0, \pi]$ an.

1	0	1	0	0	0
0	1	0	1	0	1
0	0	1	0	2	0
0	0	0	2	0	1
0	0	1	0	1	0
0	1	0	0	0	1
1	0	0	0	0	0

Tabelle 2.1: Accumulator-Array im Parameterraum (m, c)

$$\rho = x * cos(\theta) + y * sin(\theta)$$

Dadurch wird ein Speicheraufwand von n^2 bei n Punkten vermieden, der bei der klassichen Methode durch Testen aller Punktpaare entsteht. Für diese Arbeit ist die Darstellung der Koordinaten in Normalform wichtig, da sie im Python Modul OpenCV ebenfalls zum Einsatz kommt. [Ope]

Für jeden Punkt (x_0, y_0) kann denmnach eine Menge von Geraden durch folgende Gleichung gefunden werden. Der Schnittpunkt mehrerer Koordinaten gibt die Gerade an, welche durch die jeweiligen Punkte verläuft. Die Abbildung 2.2 veranschaulicht das Konzept.

$$\rho = x_0 * cos(\theta) +_0 *sin(\theta)$$

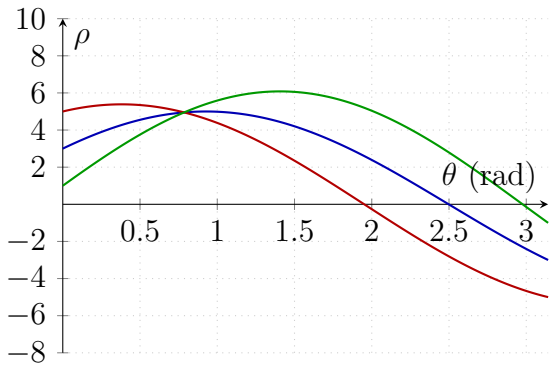

Abbildung 2.2: Parameterraum in Polarkoordinaten

2.3 Homographie

Eine Homographie, auch projektive Transformation, ist eine bijektive Abbildung, welche geradlinien erhält. Sie beschreibt die mathematische Beziehung zwischen zwei Bildern

derselben planaren Oberfläche oder zwischen zwei Bildern, die von derselben Kamera aus verschiedenen Rotationswinkeln aufgenommen wurden.

Die Homographie wird durch eine 3x3 Matrix H in homogenen Koordinaten dargestellt. Für einen Bildpunkt x im Ausgangbild gilt der korrespondierende Punkt x' im Zielbild. [Ope26; Sze22]

$$x' = H * x$$

2.4 Homogene Koordinaten

Homogene Koordinaten sind eine Darstellung von Punkten im n-dimensionalen Raum durch (n+1)-dimensionale Vektoren, wobei alle skalaren Vielfachen desselben Vektors als äquivalent betrachtet werden.

Formal gilt: Ein Punkt (u, v) in der kartesischen Ebene $\mathbb{R}^2$ wird in homogenen Koordinaten als Tripel (x, y, w) dargestellt, wobei gilt:

$$(u, v) \longleftrightarrow (x, y, w) \quad \text{mit} \quad u = \frac{x}{w},\ v = \frac{y}{w},\ w \neq 0$$

2.5 Convolutional Neural Networks (CNNs)

2.6 U-Net Architektur

2.7 Evaluationsmetriken

3 Methodik

In diesem Kapitel werden die Funktionsweisen der beiden Ansätze - algorischmisch und KI-basiert - detailliert beschrieben.

3.1 Algorithmischer Ansatz

Inhalte dieses Kapitels:

- Aufbereitung des Fotos (Canny + Blur)
- Erkennung des Größten Kreises (Rand der Dartscheibe)
- Anpassung der Perspektive
- Finden der Ringe
- Erkennen der Linien
- Berechnung des Scores

Der algorithmische Ansatz verfolgt das Ziel, eine Dartscheibe in einem mobilen Foto vollständig zu lokalisieren, zu entzerren und ihre Felder geometrisch zu segmentieren – ohne den Einsatz lernbasierter Verfahren.

Grundvoraussetzung für diesen Ansatz ist, dass die Dartscheibe im Bild als Kreis dargestellt ist. Damit ist die Perspektivische Korrektur hier nicht berücksichtigt.

Die Abbildung 3.1 veranschaulicht die algorithmische Pipeline. Nachfolgend wird jeder Punkt im Detail beschrieben.

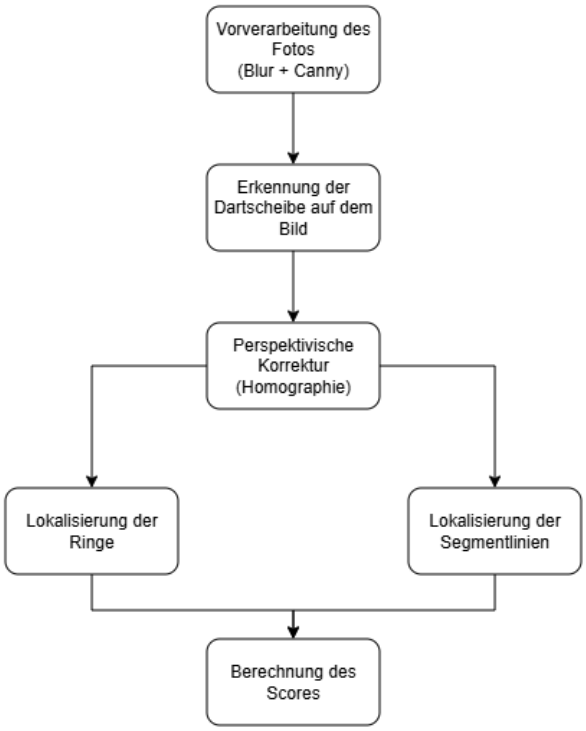

Abbildung 3.1: Übersicht über die algorithmische Pipeline

3.1.1 Vorverarbeitung

Als erster Schritt der Pipeline wird das Eingangsfoto, das auf eine Auflösung von 3000 x 4000 Pixeln festgelegt wurde, vorverarbeitet und für die weitere Verarbeitung aufbereitet. Hierzu wird das Bild vom RGB- in das Graustufenformat konvertiert. Zur Reduktion von Bildrauschen kommt ein Median-Filter mit einer Kernelgröße von $k = 11$ zum Einsatz. Im Vergleich zu anderen Filtern, beispielsweise dem Gaußschen Weichzeichner, eignet sich der Median-Filter besser für die Vorverarbeitung von Dartscheibenaufnahmen, da er Salz- und Pfeffer-Rauschen effektiv unterdrückt, ohne die für die nachfolgende Kantendetektion relevanten Übergänge zwischen den Feldbereichen zu verwischen [Ope25].

3.1.2 Erkennung der Dartscheibe im Bild

Die Lokalisierung der Dartscheibe erfolgt mittels der Hough-Kreiserkennung, die auf dem vorverarbeiteten Graustufenbild operiert. Da die Scheibengröße im Bild je nach Aufnahmeabstand variiert, werden der minimale und maximale Suchradius dynamisch in Abhängigkeit der kürzeren Bildkante berechnet. Ausgehend von einem initialen Wertebereich von 70 % bis 75 % der Bildkantenlänge wird der Suchbereich iterativ um jeweils 5 % reduziert, sofern keine Kreishypothese gefunden wurde. Dieses Vorgehen stellt sicher, dass

auch bei ungewöhnlichen Bildproportionen oder größeren Aufnahmeabständen eine Erkennung möglich bleibt, solange die Scheibe einen Mindestanteil von ca. 10 % der Bildbreite einnimmt.

Die Hough-Transformation wird mit einem Akkumulatorschwellwert von `param2` = 200 und einem Kantenschwellwert von `param1` = 300 konfiguriert, die empirisch ermittelt wurden. Da viele Dartscheiben mit einem äußeren Schutzring versehen sind, dessen Radius den der eigentlichen Scheibe übersteigt, wird bei mehreren erkannten Kreishypothesen jene mit dem kleinsten Radius als Scheibenrand selektiert.

3.1.3 Perspektivische Korrektur und Normalisierung

Nach der Lokalisierung der Dartscheibe wird das Eingabebild mittels einer Homographie auf ein einheitliches quadratisches Format von 1024×1024 Pixeln transformiert. Ziel dieser Normalisierung ist es, die anschließende geometrische Feldsegmentierung unabhängig von Aufnahmeabstand und Bildauflösung zu gestalten.

Die Homographie wird auf Basis von vier Korrespondenzpunkten berechnet. Als Quellpunkte dienen die vier Ecken des achsenparallelen Begrenzungsrahmens (*Bounding Box*) des erkannten Kreises, die sich aus Mittelpunkt (c_x, c_y) und Radius r wie folgt ergeben:

$$P_{\text{src}} = \begin{pmatrix} c_x - r & c_y - r \\ c_x + r & c_y - r \\ c_x + r & c_y + r \\ c_x - r & c_y + r \end{pmatrix} \tag{3.1}$$

Die Zielpunkte P_{dst} entsprechen den vier Ecken des (1024×1024)-Ausgabebildes. Die Homographiematrix H wird mittels `cv2.getPerspectiveTransform` aus diesen Punktpaaren berechnet und anschließend per `cv2.warpPerspective` auf das Originalbild angewendet.

Dieser Ansatz setzt voraus, dass die Kamera annähernd frontal auf die Dartscheibe gerichtet ist. Da die Quellpunkte aus der achsenparallelen Begrenzungsbox des erkannten Kreises abgeleitet werden, enthält die berechnete Homographie keine Information über die tatsächliche räumliche Orientierung der Scheibe. Bei stärkerer perspektivischer Verzerrung führt dies zu einer unvollständigen Entzerrung, was die Zuverlässigkeit der nachgelagerten Feldsegmentierung beeinträchtigt. Diese Einschränkung motiviert den in Kapitel 3.2 beschriebenen Machine-Learning-Ansatz, der eine robustere Grundlage für die perspektivische Korrektur bietet.

3.1.4 Lokalisierung der Ringe

Nach der perspektivischen Normalisierung liegt die Dartscheibe als frontale Draufsicht im einheitlichen 1024×1024-Format vor. In diesem Koordinatensystem befindet sich der Scheibenmittelpunkt näherungsweise bei $(512, 512)$. Die geometrische Struktur einer Dartscheibe besteht aus konzentrischen Ringen mit definierten Radien, die auf Basis der normierten Darstellung mittels erneuter Hough-Kreiserkennung detektiert werden.

Die Implementierung der Hough-Transformation durch die Bibliothek opencv-python enthält einen Parameter `minDist`. Dieser gibt den minimalen Abstand zwischen zwei erkannten Kreisen in Pixel an. Dies ist für die Erkennung der Ringsegmente einer Dartscheibe problematisch, da sich diese einen Mittelpunkt teilen, wobei sich nur die Radien unterscheiden. Da sich dieser Parameter nicht auf 0 setzen lässt ist es notwendig die Hough-Transformation ringweise auszuführen. Für jeden Ring ist ein enger Suchbereich $[r_{\min}, r_{\max}]$ definiert, der aus den bekannten Proportionen einer Dartscheibe abgeleitet wurde. Tabelle 3.1 listet die verwendeten Ringe und ihre jeweiligen Suchbereiche.

Ring	$r_{\min}$ (px)	$r_{\max}$ (px)
Bulls-Eye	0	25
Outer Bull	30	60
Inner Triple	190	230
Outer Triple	240	270
Inner Double	340	385
Outer Double	390	450

Tabelle 3.1: Suchbereiche der Hough-Kreiserkennung je Ring im normierten 1024×1024-Koordinatensystem.

Für jeden Suchbereich wird die Hough-Transformation mit einem Akkumulatorschwellwert von `param2` $= 50$ und einem Kantenschwellwert von `param1` $= 220$ ausgeführt. Der niedrigere Akkumulatorschwellwert gegenüber der initialen Scheibenerkennung ist dabei bewusst gewählt, da die Ringkanten im normierten Bild feiner und weniger dominant sind als der äußere Scheibenrand.

Liefert die Hough-Transformation mehrere Kreishypothesen innerhalb eines Suchbereichs, wird jene selektiert, deren Mittelpunkt den geringsten euklidischen Abstand zum Referenzpunkt $(512, 512)$ aufweist:

$$c^* = \arg\min_{c \in \mathcal{C}} \; (c_x - x_{\text{ref}})^2 + (c_y - y_{\text{ref}})^2 \tag{3.2}$$

wobei $\mathcal{C}$ die Menge aller erkannten Kreishypothesen im jeweiligen Suchbereich bezeichnet. Wird für einen Ring keine Hypothese gefunden, wird dieser übersprungen und in der nachgelagerten Feldsegmentierung als nicht erkannt behandelt.

3.1.5 Lokalisierung der Segmentlinien

3.1.6 Berechnung des Scores

3.2 Machine Learning Ansatz

Inhalte dieses Kapitels:

- Vergleich zwichen U-Net, YOLOv11 und Mask R-CNN (Welcehs Modell am geeignetsten)
- Diskurs: Segmentierung des gesamten Boards mithilfe eines Modells

Erweiterung des Algorithmischen Ansatzes um die Erkennung der Dartscheibe, um perspektivische Korrektur der Dartscheibe hinzubekommen.

Oder folgender Ansatz:

- Erkennung der Scheibe
- perspektivische Korrektur
- Erkennung der Linien (und Kreise) mit jeweils anderem Modell
- Berechnung des Scores mithilfe der gleichen Methode wie im algorithmischen Ansatz.

3.3 Evaluation

Hier Beschreibe ich die Funktionsweise meines Evaluations-Frameworks. Ich muss hier möglichst genau beschreiben, wie der Vergleich stattfindet, welche Kriterien ich wähle und wie ich sie messe. Das komplette Evaluationsframework eben.

Wie die einzelnen Ansätze dann abschneiden kommt in den Ergebnisse Part.

4 Ergebnisse

Hier kommt mein Evaluations-Framework zum Einsatz. Ich vergleiche hier, wie die einzelnen Ansätze abgeschnitten haben. Ich sollte pro Ansatz auf jedes Kriterium eingehen.

5 Fazit und Ausblick

Hier beschreibe ich, welcher Ansatz der "Besteïst und auch warum. Außerdem kann ich hier schreiben, welche Probleme zu den schlechten Ergebnissen der anderen Ansätze geführt haben und wie man das evtl. beheben könnte.

Literatur

[Can86] John Canny. „A Computational Approach to Edge Detection“. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* PAMI-8.6 (Nov. 1986), S. 679–698. ISSN: 1939-3539. DOI: 10.1109/TPAMI.1986.4767851. URL: https://ieeexplore.ieee.org/abstract/document/4767851 (besucht am 27. 11. 2025).

[DH72] Richard O. Duda und Peter E. Hart. „Use of the Hough transformation to detect lines and curves in pictures“. In: *Commun. ACM* 15.1 (Jan. 1972), S. 11–15. ISSN: 0001-0782. DOI: 10.1145/361237.361242. URL: https://dl.acm.org/doi/10.1145/361237.361242 (besucht am 06. 04. 2026).

[Hou62] F V C Hough. „METHOD AND MEANS FOR RECOGNIZING COMPLEX PATTERNS“. en. In: (1962).

[IK88] J. Illingworth und J. Kittler. „A survey of the hough transform“. In: *Computer Vision, Graphics, and Image Processing* 44.1 (Okt. 1988), S. 87–116. ISSN: 0734-189X. DOI: 10.1016/S0734-189X(88)80033-1. URL: https://www.sciencedirect.com/science/article/pii/S0734189X88800331 (besucht am 30. 03. 2026).

[Ope] OpenCV. *OpenCV: Image Processing (imgproc module)*. URL: https://docs.opencv.org/3.4/d7/da8/tutorial_table_of_content_imgproc.html (besucht am 06. 04. 2026).

[Ope25] OpenCV. *OpenCV: Smoothing Images*. Juli 2025. URL: https://docs.opencv.org/3.4/d4/d13/tutorial_py_filtering.html (besucht am 25. 04. 2026).

[Ope26] OpenCV. *Basic concepts of the homography explained with code*. 2026. URL: https://docs.opencv.org/4.x/d9/dab/tutorial_homography.html (besucht am 14. 03. 2026).

[Sze22] Richard Szeliski. *Computer Vision: Algorithms and Applications*. en. Texts in Computer Science. Cham: Springer International Publishing, 2022. ISBN: 978-3-030-34371-2 978-3-030-34372-9. DOI: 10.1007/978-3-030-34372-9. URL: https://link.springer.com/10.1007/978-3-030-34372-9 (besucht am 27. 11. 2025).

Anhang

Hier ist etwas für den Anhang.