System zur Segmentierung einer Dart-Scheibe

Studienarbeit

des Studiengangs Informatik

an der DHBW Stuttgart Campus Horb

von

Din Alomerovic

4. Mai 2026

Bearbeitungszeitraum	12 Wochen
Matrikelnummer, Kurs	1234567, INF20xx
Betreuer	Philipp Kremling

Ehrenwörtliche Erklärung

Ich versichere hiermit, dass ich meine Arbeit mit dem Thema *System zur Segmentierung einer Dart-Scheibe* selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe.

Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Ich habe bei der Erstellung der Arbeit KI-Werkzeuge eingesetzt. Dies habe ich an den entsprechenden Stellen der Arbeit kenntlich gemacht.

ORT, DATUM

AUTOR

Abstract

HIER IST MEINE ZUSAMMENFASSUNG

Inhaltsverzeichnis

Abkürzungsverzeichnis **V**

Abbildungsverzeichnis **VI**

Tabellenverzeichnis **VII**

Listings **VIII**

1 Einleitung **1**

2 Theoretische Grundlagen **4**
2.1 Canny-Kantendetektion 4
2.2 Hough Transformation 5
2.2.1 Erkennung von Linien 5
2.2.2 Erkennung von Kreisen 7
2.3 Homographie 8
2.4 U-Net Architektur 9
2.5 Evaluationsmetriken 9
2.5.1 Inferenzzeit 9
2.5.2 Intersection over Union 9

3 Methodik **11**
3.1 Algorithmischer Ansatz 12
3.1.1 Vorverarbeitung 12
3.1.2 Erkennung der Dartscheibe 12
3.2 Machine Learning Ansatz 13
3.2.1 Erkennung der Dartscheibe 13
3.2.2 Nachverarbeitung der Maske 13
3.3 Gemeinsame Verarbeitungsschritte 13
3.3.1 Perspektivische Korrektur und Normalisierung 13
3.3.2 Lokalisierung der Ringe 14
3.3.3 Lokalisierung der Segmentlinien 15
3.3.4 Berechnung des Scores 16
3.4 Evaluation 18

4 Design und Implementierung **20**
4.1 Algorithmischer Ansatz 20
4.1.1 Vorverarbeitung 20
4.1.2 Erkennung der Dartscheibe 21

4.2 Machine Learning Ansatz 22
4.2.1 Erkennung der Dartscheibe 22
4.2.2 Nachverarbeitung der Maske 22
4.3 Gemeinsame Verarbeitungsschritte 22
4.3.1 Perspektivische Korrektur und Normalisierung 22
4.3.2 Lokalisierung der Ringe 22
4.3.3 Lokalisierung der Segmentlinien 22
4.3.4 Berechnung des Scores 22

5 Ergebnisse **23**

6 Fazit und Ausblick **24**

Literatur **25**

Anhang **28**

Abkürzungsverzeichnis

HT Hough Transformation

Abbildungsverzeichnis

2.1 Grundprinzip der Hough-Transformation 6
2.2 Parameterraum in Polarkoordinaten 7
2.3 Hough-Transformation zur Kreiserkennung. *Links:* Datenpunkte im (x, y)-Bildraum liegen auf einem gemeinsamen Kreis. *Rechts:* Jeder Datenpunkt erzeugt im Parameterraum (a, b) einen eigenen Kreis 8

3.1 Übersicht über die algorithmische Pipeline 11
3.2 Geometrische Grundlage der Score-Berechnung im normierten Scheibenkoordinatensystem. Der Auftreffpunkt P wird durch den Polarwinkel φ und den Radius r eindeutig einem Winkelsegment sowie einer radialen Wertungszone zugeordnet. 18

Tabellenverzeichnis

2.1 Accumulator-Array im Parameterraum (m, c) 6

3.1 Suchbereiche der Hough-Kreiserkennung je Ring im normierten 1024×1024-Koordinatensystem. 14

3.2 Radiale Feldzuordnung und zugehörige Punktwerte. b bezeichnet den Grundwert des getroffenen Winkelsegments. 17

Listings

1 Einleitung

Beim Dartspielen stellt das manuelle Zählen der Punkte für viele Hobbyspielerinnen und Hobbyspieler weiterhin eine zentrale Hürde dar, da es als zeitaufwändig, fehleranfällig und wenig intuitiv empfunden wird. Zwar existieren digitale Alternativen wie etwa elektronische Dartscheiben, doch bevorzugen viele Spielerinnen und Spieler weiterhin klassische Boards mit echten Pfeilen. Daraus erwächst der Wunsch nach einer Lösung, die das Punktezählen kontaktlos und ohne zusätzliches Equipment ermöglicht - idealerweise allein basierend auf einem Smartphone-Foto.

Für eine präzise, automatisierte Score-Ermittlung ist die zuverlässige digitale Repräsentation der Dartscheibenstruktur eine grundlegende Voraussetzung. Damit die geworfenen Punkte eindeutig den entsprechenden Feldern zugeordnet werden können, muss die Dartscheibe in einem aufgenommenen Bild robust erkannt, perspektivisch korrigiert und geometrisch segmentiert werden. Dieser Prozess ist wesentlicher Bestandteil der Bildverarbeitungspipeline und bildet die algorithmische Grundlage für sämtliche nachgelagerten Analyse- und Klassifikationsschritte.

Die technische Umsetzung dieser Segmentierung birgt jedoch mehrere Herausforderungen. Die klassische Dartscheibe, weist aufgrund ihrer ringförmigen Struktur, kontrastintensiven Farbfelder, feinen Segmentlinien sowie metallischer oder faserbasierter Materialien eine komplexe Erscheinung auf. Variierende Kamerawinkel erzeugen projektive Verzerrungen, die ohne geeignete Transformation zu fehlerhaften Feldzuordnungen führen würden. Zusätzlich erschweren wechselnde Lichtbedingungen, Reflexionen der Metall-Score-Ringe, Verdeckungen durch bereits steckende Dartpfeile, schlechter Zustand der Scheibe durch intensive Nutzung sowie unterschiedliche Hintergründe das Erkennen der einzelnen Konturen einer Dartscheibe.

Zur Lösung dieser Problematik stehen einerseits klassische, algorithmische Verfahren der Bildverarbeitung zur Verfügung - etwa Hough-Transformationen zur Kreis-Detektion, Canny-Edge-Filtering zur Kantenerkennung oder homographiebasierte Perspektivkorrekturen. Andererseits existieren moderne Deep-Learning-Ansätze, die mittels neuronaler Netze und semantischer Segmentierung (z. B. über architekturen wie U-Net) eine lernbasierte Erkennung ermöglichen. Ein Schwerpunkt dieser Studienarbeit besteht darin, die Ansätze hinsichtlich Robustheit, Erkennungsgenauigkeit, Implementierungsaufwand und Verarbeitungsgeschwindigkeit systematisch zu vergleichen.

Da die Bildaufnahme durch die Nutzerinnen und Nutzer nicht standardisiert erfolgt, unterscheiden sich die Fotos je nach Standpunkt, Distanz und Kamerawinkel teils erheblich voneinander. Die Position der fotografierenden Person variiert von Aufnahme zu Aufnahme, wodurch die Dartscheibe im Bild unterschiedlich groß erscheint und projektive Verzerrungen entstehen. Eine robuste Lösung muss daher unabhängig von festen Aufnahmepositionen funktionieren und in der Lage sein, perspektivische Abweichungen zuverlässig zu normalisieren. Diese Problematik stellt eine zusätzliche Herausforderung dar, da klassische regelbasierte Verfahren häufig feste geometrische Annahmen treffen, während lernbasierte Ansätze genügend Generalisierung für freie Aufnahmesituationen benötigen.

Ziel dieser Studienarbeit ist die Entwicklung und Evaluation eines robusten, ausschließlich auf Smartphone-Fotos basierenden Verfahrens zur zuverlässigen Dartboard-Erkennung, perspektivischen Normalisierung und geometrisch exakten Segmentierung klassischer Dartscheiben. Das Verfahren soll insbesondere unabhängig von der Position der Aufnahme, skalierungsinvariant und fehlertolerant gegenüber realen Störfaktoren wie ungünstigen Lichtverhältnissen oder teilweisen Verdeckungen durch bereits steckende Pfeile funktionieren. Es bildet damit die essenzielle Grundlage für eine spätere, feldgenaue Punktzuordnung und automatisierte Score-Berechnung.

Der methodische Schwerpunkt der Arbeit liegt auf der Konzeption eines klassischen, algorithmischen Computer-Vision-Ansatzes, bei dem die Scheibenregion primär über eine Kreiserkennung mittels Hough-Transformation lokalisiert wird. Um die dafür relevanten Kanteninformationen zu extrahieren, wird das Eingangsfoto zunächst durch Canny-Edge-Filtering aufbereitet. Anschließend soll eine homographiebasierte Perspektivtransformation eine orthogonale Board-Draufsicht erzeugen, aus der die Feldgeometrie über ein mathematisch definiertes Dartboard-Modell (Ring- und Radialgitter) berechnet und in einzelne Scoring-Segmente überführt wird.

Neben dem klassischen Computer-Vision-Ansatz verfolgt die Arbeit das Ziel, einen lernbasierten Lokalisierungsansatz zu entwickeln und zu evaluieren. Hierfür soll ein U-Net-basiertes Deep-Learning-Modell eingesetzt werden, das die Dartscheibe semantisch im Bild segmentiert und ihre Position als Pixelmaske vorhersagt. Auf eine vollständige Feldsegmentierung mittels Deep Learning wird dabei bewusst verzichtet: Da alle Felder einer Dartscheibe nahezu identische visuelle Merkmale aufweisen und sich lediglich durch ihre geometrische Position unterscheiden, wäre ein solches Modell auf einen umfangreichen, sorgfältig annotierten Datensatz angewiesen, dessen Erstellung den Rahmen dieser Arbeit übersteigen würde. Stattdessen übernimmt das U-Net-Modell ausschließlich die grobe Lokalisierung der Scheibe im Bild, während die präzise Segmentierung der einzelnen Felder anschließend durch einen geometrisch-algorithmischen Ansatz auf Basis von Homogra-

phie und Kreisgeometrie erfolgt. Ein zentraler Gegenstand der Zielsetzung ist dabei der Vergleich dieses Hybridansatzes mit einer rein algorithmischen Pipeline, um Stärken und Schwächen beider Varianten hinsichtlich Robustheit, Genauigkeit und praktischer Eignung für den mobilen Einsatz zu bewerten.

Sollte im Projektverlauf noch Zeit verbleiben, wird zusätzlich eine prototypische Kopplung mit einer komplementären Arbeit angestrebt, die Dartpfeile im Bild erkennt und deren Position bestimmt. Die Kombination beider Verfahren ermöglicht perspektivisch die Realisierung einer vollständigen, automatisierten Score-Ermittlung als Basis für eine nutzerfreundliche Dart-Scoring-App, die das analoge Spielgefühl klassischer Boards mit digitaler Unterstützung verbindet.

Im Mittelpunkt dieser Arbeit steht die folgende übergeordnete Leitfrage:

> *Welcher Ansatz – algorithmisch oder KI-basiert – bietet für die Lokalisierung und Segmentierung einer Dartscheibe in mobilen Fotos die bessere Gesamtbalance zwischen Implementierungsaufwand, Erkennungsgenauigkeit, Robustheit gegenüber realen Aufnahmebedingungen und Verarbeitungsgeschwindigkeit?*

Zur Beantwortung dieser Leitfrage werden die folgenden untergeordneten Forschungsfragen untersucht:

- **Algorithmische Lokalisierung:** Wie robust und präzise lässt sich eine Dartscheibe in mobilen Fotos mittels Canny-Filterung und Hough-Kreiserkennung lokalisieren und anschließend per Homographie entzerren?
- **KI-basierte Lokalisierung:** Welche Erkennungsgenauigkeit erreicht ein U-Net-Modell bei der Lokalisierung von Dartscheiben unter variierenden Aufnahmebedingungen auf mobilen Endgeräten?
- **Hybridansatz:** Inwiefern verbessert eine vorgelagerte KI-basierte Lokalisierung die Genauigkeit der anschließenden algorithmischen Feldsegmentierung gegenüber einem rein algorithmischen Pipeline-Ansatz?
- **Robustheit und Störfaktoren:** Welche Aufnahmebedingungen – insbesondere Lichtverhältnisse, Perspektive, Skalierung und Verdeckungen – beeinträchtigen die Lokalisierungsgenauigkeit beider Ansätze am stärksten?

2 Theoretische Grundlagen

2.1 Canny-Kantendetektion

Der Canny-Kantendetektor, erstmals von John Canny im Jahr 1986 vorgestellt [Can86], stellt einen mehrstufigen Algorithmus dar, dessen Grundlage eine formale mathematische Definition der Zielsetzung eines idealen Kantendetektors bildet. Canny formulierte die Kantenerkennung als Optimierungsproblem und leitete drei mathematische Kriterien ab, denen ein optimaler Detektor für stufenförmige Kanten genügen muss. Aus diesen Kriterien wurde eine spezifische Operatorform hergeleitet, sodass der Algorithmus als deren direkte technische Umsetzung zu verstehen ist.

1. **Gute Erkennungrate:** Die Fehlerwahrscheinlichkeit, echte Kanten zu übersehen oder fälschlicherweise Nicht-Kanten zu markieren, muss minimiert werden.

2. **Gute Lokalisierung:** Die markierte Kantenposition soll eine minimale Abweichung vom tatsächlichen Kantenzentrum aufweisen.

3. **Eindeuige Antwort:** Der Detektor darf auf eine einzelne Kante nicht mit mehreren lokalen Maxima antworten.

Der Canny-Kantendetektor arbeitet in vier aufeinanderfolgenden Schritten. Zunächst wird das Eingabebild durch Faltung mit einem Gauß-Filter geglättet, um hochfrequentes Rauschen zu unterdrücken, wobei die Standardabweichung σ als zentraler Parameter die Robustheit gegenüber der Lokalisierungsgenauigkeit abwägt. Anschließend werden für jeden Pixel Kantenstärke und Kantenrichtung aus dem Gradienten des geglätteten Bildes berechnet, bevor im dritten Schritt die Nicht-Maxima-Unterdrückung die Kantenantworten durch Beibehaltung ausschließlich lokaler Maxima entlang der Gradientenrichtung auf eine Pixelbreite reduziert.

Den abschließenden und für die Qualität des Ergebnisses entscheidenden Schritt bildet die Klassifikation mittels Hysterese-Schwellwertverfahren. Dieses verwendet zwei Schwellwerte T_1 und T_2, wobei Pixel oberhalb von T_1 als sichere Kanten klassifiziert werden, während Pixel im Intervall $[T_2, T_1]$ nur dann akzeptiert werden, wenn sie räumlich mit einer sicheren Kante verbunden sind. Durch diesen zweistufigen Mechanismus wird das als *Streaking* bekannte Abreißen von Kantenzügen infolge lokaler Schwankungen der Kantenstärke zuverlässig verhindert.

2.2 Hough Transformation

In diesem Kapitel werden die Grundlagen der Hough Transformation (HT) vermittelt. Dabei wird zuerst die Funktionsweise der Erkennung von Linien und anschließend die Erkennung von Kreisen erklärt.

2.2.1 Erkennung von Linien

Die HT ist ein grundlegendes Verfahren der digitalen Bildverarbeitung und des maschinellen Sehens, das der Erkennung geometrischer Formen und Muster in Bilddaten dient. Sie wurde ursprünglich von Paul Hough im Jahr 1962 in einem Patent zur Erkennung komplexer Muster in Blasenkammeraufnahmen vorgestellt. [IK88; Hou62].

Die Funktionsweise der HT veranschaulicht die Abbildung 2.1. Dabei werden Punkte aus dem ursprünglichen Bildraum in den Parameterraum transformiert. Der Bildraum ist im klassischen Sinne der Raum in dem Punkte in x und y Koordinaten angegeben werden. Der Parameterraum bezieht sich hingegen auf die beiden Parameter m und c einer Geraden. Eine wichtige Eigenschaft hierbei ist, dass Punkte im Bildraum durch die Transformation zu Geraden im Parameterraum werden. Der Schnittpunkt der Geraden im Parameterraum gibt die Parameter m und c der Geraden an, durch die die jeweiligen Punte im Bildraum verbunden werden. [IK88]

Um die HT berechnen zu können, wird der Parameterraum als ein mehrdimensionales Array, das sogenannte Akkumulator-Array, dargestellt, wobei jedes Element hochgezählt wird, sobald eine Gerade dadurch verläuft. Die Erkennung von Hochpunkten ist im Parameterraum einfacher und rechnerisch weniger fordernd als im Bildraum. [IK88] Die Tabelle 2.1 dient dafür als Veranschaulichung.

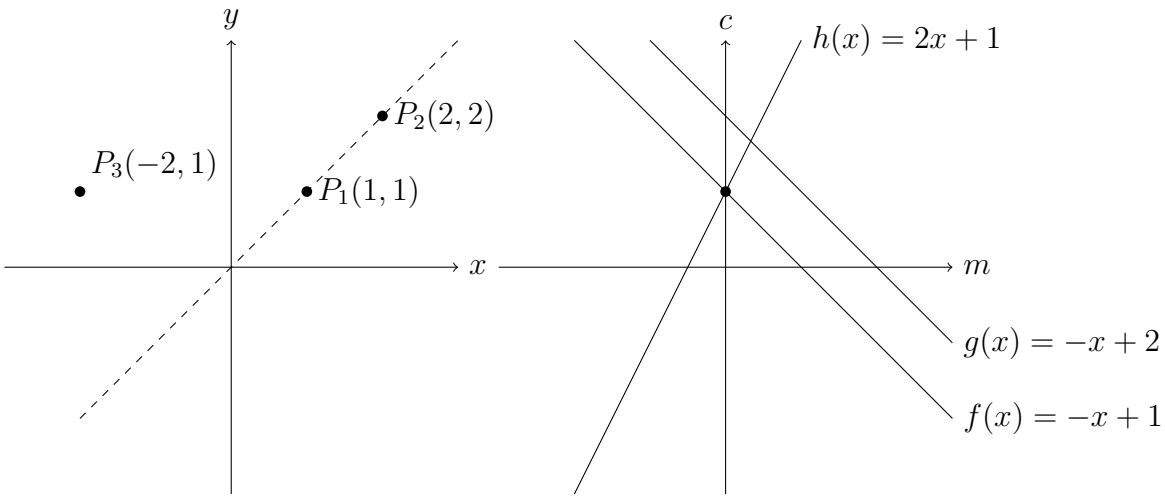

(a) Punkte im Bildraum (b) Punkte im Parameterraum

Abbildung 2.1: Grundprinzip der Hough-Transformation

1	0	1	0	0	0
0	1	0	1	0	1
0	0	1	0	2	0
0	0	0	2	0	1
0	0	1	0	1	0
0	1	0	0	0	1
1	0	0	0	0	0

Tabelle 2.1: Accumulator-Array im Parameterraum (m, c)

In einer Veröffentlichung von Duda und Hart [DH72] wurde vorgeschlagen, dass man statt der ursprünglichen Geradenform mit m und c die Normalform welche durch folgende Gleichung beschrieben wird nutzt. Dabei gibt ρ den Abstand der Geraden zum Ursprung und θ den Winkel der Normalen zur Gerade im Intervall [0, π] an.

$$\rho = x * cos(\theta) + y * sin(\theta)$$

Dadurch wird ein Speicheraufwand von n^2 bei n Punkten vermieden, der bei der klassichen Methode durch Testen aller Punktpaare entsteht. Für diese Arbeit ist die Darstellung der Koordinaten in Normalform wichtig, da sie im Python Modul OpenCV ebenfalls zum Einsatz kommt. [Ope]

Für jeden Punkt (x_0, y_0) kann denmnach eine Menge von Geraden durch folgende Gleichung gefunden werden. Der Schnittpunkt mehrerer Koordinaten gibt die Gerade an, welche durch die jeweiligen Punkte verläuft. Die Abbildung 2.2 veranschaulicht das Konzept.

$$\rho = x_0 * cos(\theta) +_0 *sin(\theta)$$

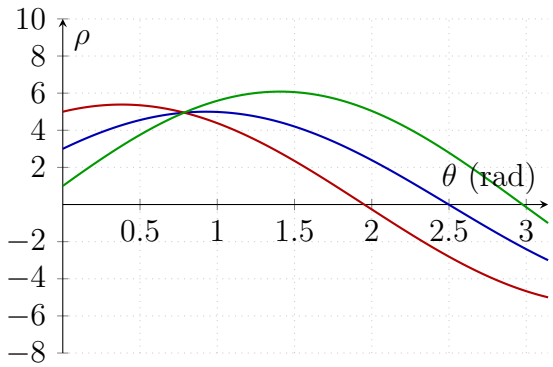

Abbildung 2.2: Parameterraum in Polarkoordinaten

2.2.2 Erkennung von Kreisen

Die Erkennung von Kreisen basiert auf demselben Prinzip wie die zuvor beschriebene Linienerkennung, jedoch wird anstelle der Geradengleichung die Kreisgleichung

$$(x_i - a)^2 + (y_i - b)^2 = r^2$$

als parametrische Darstellung verwendet, wobei a und b die Koordinaten des Kreismittelpunkts und r den Radius bezeichnen. x_i und y_i sind die Koordinaten eines auf dem Kreis liegenden Punktes P_i. Zur Reduktion der Problemkomplexität wird der Radius r zunächst als bekannt vorausgesetzt, sodass der zweidimensionale Parameterraum ausschließlich durch die Mittelpunktkoordinaten a und b aufgespannt wird. Wie in Abbildung 2.3 dargestellt, wird jeder Bildpunkt im Parameterraum als Kreis repräsentiert, dessen Schnittpunkt mit den übrigen transformierten Punkten den gesuchten Kreismittelpunkt bestimmt. [IK88]

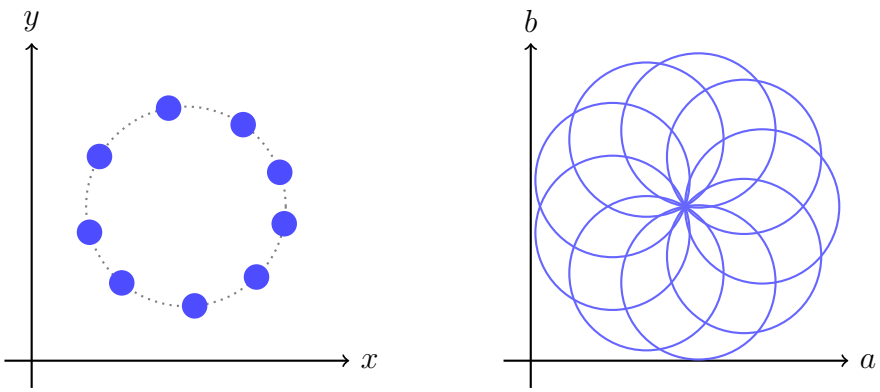

Abbildung 2.3: Hough-Transformation zur Kreiserkennung. *Links:* Datenpunkte im (x, y)-Bildraum liegen auf einem gemeinsamen Kreis. *Rechts:* Jeder Datenpunkt erzeugt im Parameterraum (a, b) einen eigenen Kreis

2.3 Homographie

Eine Homographie, auch als projektive Transformation bezeichnet, ist eine bijektive Abbildung, welche die Geradlinigkeit von Punkten erhält. Sie beschreibt die mathematische Beziehung zwischen zwei Bildern derselben planaren Oberfläche oder zwischen zwei Aufnahmen, die von derselben Kamera unter verschiedenen Rotationswinkeln aufgenommen wurden [Sze22].

Die Transformation wird durch eine 3×3-Matrix H in homogenen Koordinaten repräsentiert. Für einen Bildpunkt x im Ausgangsbild ergibt sich der korrespondierende Punkt x' im Zielbild gemäß

$$\begin{bmatrix} x' \\ y' \\ w' \end{bmatrix} = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} \begin{bmatrix} x \\ y \\ w \end{bmatrix}.$$

Obwohl H neun Einträge besitzt, ist sie lediglich bis auf einen Skalierungsfaktor definiert, sodass sie effektiv über acht Freiheitsgrade verfügt [Ope26]. Da jede Punktkorrespondenz zwei Gleichungen liefert, sind zur eindeutigen Bestimmung von H mindestens vier nicht-kollineare Punktkorrespondenzen erforderlich [Sze22].

In der Praxis wird H mittels des Direct Linear Transform (DLT)-Verfahrens geschätzt. Um die Robustheit gegenüber Ausreißern in den Korrespondenzen zu gewährleisten, wird DLT typischerweise in Kombination mit dem RANSAC-Algorithmus eingesetzt [Ope26].

Die Homographie findet in zahlreichen Bereichen der Computer Vision Anwendung, darunter die Perspektivkorrektur, das Zusammensetzen von Panoramabildern sowie die Überlagerung virtueller Objekte in Augmented-Reality-Systemen [Sze22; Ope26].

2.4 U-Net Architektur

2.5 Evaluationsmetriken

2.5.1 Inferenzzeit

Die Inferenzzeit bezeichnet im Kontext neuronaler Netze die Zeitspanne, die ein bereits trainiertes Modell benötigt, um aus neuen Eingabedaten eine Vorhersage zu erzeugen. Im Gegensatz zur Trainingsphase werden dabei keine Modellparameter angepasst; vielmehr erfolgt ausschließlich die Anwendung des trainierten Modells auf unbekannte Daten [GBC16].

Für Objekterkennungssysteme beschreibt die Inferenzzeit die Dauer zwischen der Bereitstellung eines Eingabebildes und der Ausgabe der Detektionsergebnisse. Sie stellt insbesondere bei zeitkritischen Anwendungen eine wesentliche Leistungskennzahl dar. Formal lässt sich die Inferenzzeit T_{inf} definieren als

$$T_{\text{inf}} = t_{\text{end}} - t_{\text{start}} \tag{2.1}$$

wobei t_{start} den Beginn der Verarbeitung und t_{end} den Zeitpunkt der Ergebnisbereitstellung beschreibt.

2.5.2 Intersection over Union

Zur Bewertung der Segmentierungsqualität bzw. Erkennungsgenauigkeit wird in der Computer-Vision-Literatur die Intersection over Union (IoU), auch als Jaccard-Index bezeichnet, als Standardmetrik eingesetzt [Eve+10]. Sie setzt die Schnittmenge der vom System erzeugten Maske M_{pred} und der Ground-Truth-Maske M_{gt} ins Verhältnis zu ihrer Vereinigungsmenge:

$$\text{IoU} = \frac{|M_{\text{pred}} \cap M_{\text{gt}}|}{|M_{\text{pred}} \cup M_{\text{gt}}|}$$

Der Wertebereich liegt zwischen 0 (keine Überlappung) und 1 (vollständige Übereinstimmung). Nach dem PASCAL-VOC-Standard gilt eine Erkennung ab einem Schwellwert von IoU $\geq 0{,}5$ als korrekt [Eve+10].

3 Methodik

In diesem Kapitel werden die Funktionsweisen des algorithmischen und des KI-basierten Ansatzes detailliert beschrieben. Die zugrunde liegende Bildverarbeitungspipeline ist in Abbildung 3.1 dargestellt und gliedert sich in die folgenden aufeinanderfolgenden Schritte: Vorverarbeitung, Erkennung der Dartscheibe, perspektivische Korrektur, Lokalisierung der Segmentringe, Lokalisierung der Segmentlinien sowie die abschließende Berechnung des Scores. Die Reihenfolge der Schritte ist dabei verbindlich und muss zwingend eingehalten werden.

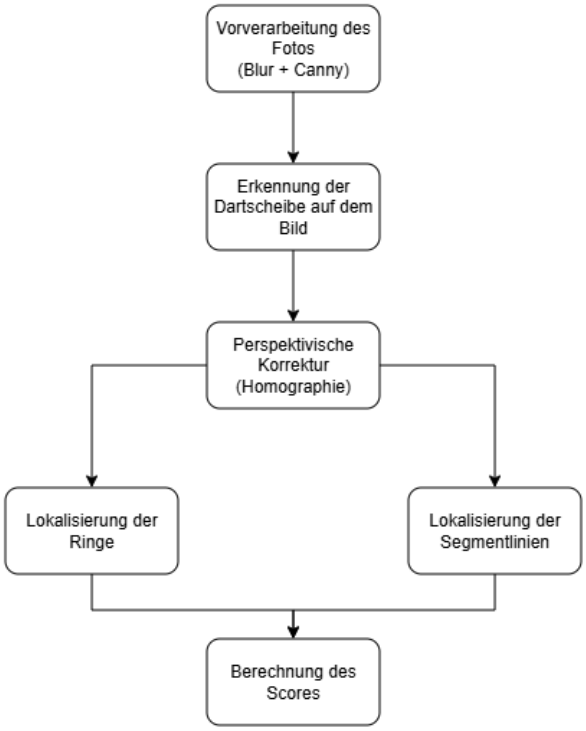

Abbildung 3.1: Übersicht über die algorithmische Pipeline

Darüber hinaus werden die Vergleichskriterien beider Ansätze erläutert sowie die Vorgehensweise beim Vergleich beschrieben.

3.1 Algorithmischer Ansatz

Der entwickelte algorithmische Ansatz dient der vollständigen Lokalisierung und geometrischen Segmentierung einer Dartscheibe in mobilen Bildaufnahmen ohne den Einsatz lernbasierter Verfahren. Dabei wird vorausgesetzt, dass die Dartscheibe in der Aufnahme näherungsweise frontal erfasst wird und somit als Kreis erscheint. Perspektivisch bedingte Verzerrungen sowie deren Korrektur konnten in diesem Ansatz nicht berücksichtigt werden.

3.1.1 Vorverarbeitung

Als erster Schritt der Pipeline wird das Eingangsfoto, das auf eine Auflösung von 3000 x 4000 Pixeln festgelegt wurde, vorverarbeitet und für die weitere Verarbeitung aufbereitet. Hierzu wird das Bild vom RGB- in das Graustufenformat konvertiert. Zur Reduktion von Bildrauschen kommt ein Median-Filter mit einer Kernelgröße von $k = 11$ zum Einsatz.

3.1.2 Erkennung der Dartscheibe

Die Lokalisierung der Dartscheibe erfolgt mittels der Hough-Kreiserkennung, die auf dem vorverarbeiteten Graustufenbild operiert.

Der minimale und maximale Suchradius werden dynamisch in Abhängigkeit der kürzeren Bildkante berechnet. Ausgehend von einem initialen Wertebereich von 70 % bis 75 % der Bildkantenlänge wird der Suchbereich iterativ um jeweils 5 % reduziert, sofern keine Kreishypothese gefunden wurde. Die Methode wird mit einem Kantenschwellwert von `param1` = 300, einem Akkumulatorschwellwert von `param2` = 200, einem minimalen Kreismittelabstand von `minDist` $= 0{,}8 \cdot h$ – wobei h die Bildhöhe bezeichnet – sowie einem inversen Auflösungsverhältnis von `dp` = 1,5 konfiguriert.

Die Ausgabe des Verfahrens ist ein erkannter Kreis, beschrieben durch Mittelpunkt (a, b) und Radius r, welcher dem Rand der Dartscheibe entspricht.

3.2 Machine Learning Ansatz

3.2.1 Erkennung der Dartscheibe

3.2.2 Nachverarbeitung der Maske

3.3 Gemeinsame Verarbeitungsschritte

Nach erfolgreicher Detektion der Dartscheibe im Bild werden, unabhängig vom jeweils verwendeten Verfahren, identische nachgelagerte Verarbeitungsschritte durchgeführt. Als Voraussetzung für diese weiteren Schritte wird die erkannte Dartscheibe in einer standardisierten geometrischen Form repräsentiert. Im Fall einer kreisförmigen Approximation erfolgt die Beschreibung durch den Mittelpunkt mit den Koordinaten x und y sowie den Radius r. Bei einer elliptischen Approximation wird die Dartscheibe durch den Mittelpunkt (x,y), die Längen der Haupt- und Nebenachse (major bzw. minor axis) sowie den Rotationswinkel der Ellipse (angle) beschrieben.

3.3.1 Perspektivische Korrektur und Normalisierung

Nach der Lokalisierung der Dartscheibe wird das Eingabebild mittels einer Homographie auf ein einheitliches quadratisches Format von 1024×1024 Pixeln transformiert. Dafür sind mindestens vier Referenzpunkte nötig, die sich abhängig davon berechnen, ob die erkannte Dartscheibe als Kreis oder Ellipse vorliegt.

Kreisförmige Spielfläche: Wird die Dartscheibe als Kreis mit Mittelpunkt (c_x, c_y) und Radius r beschrieben, so werden die vier Quellpunkte als Ecken des umbeschriebenen achsenparallelen Quadrats gewählt:

$$P_1 = \begin{pmatrix} c_x - r \\ c_y - r \end{pmatrix}, \quad P_2 = \begin{pmatrix} c_x + r \\ c_y - r \end{pmatrix}, \quad P_3 = \begin{pmatrix} c_x + r \\ c_y + r \end{pmatrix}, \quad P_4 = \begin{pmatrix} c_x - r \\ c_y + r \end{pmatrix} \tag{3.1}$$

Die Punkte sind symmetrisch um den Mittelpunkt verteilt und spannen ein Quadrat auf, dessen Seitenlänge dem Durchmesser $2r$ des Kreises entspricht.

Elliptische Spielfläche:

3.3.2 Lokalisierung der Ringe

Nach der perspektivischen Normalisierung liegt die Dartscheibe als frontale Draufsicht im einheitlichen 1024×1024-Format vor. In diesem Koordinatensystem befindet sich der Scheibenmittelpunkt näherungsweise bei $(512, 512)$. Die geometrische Struktur einer Dartscheibe besteht aus konzentrischen Ringen mit definierten Radien, die auf Basis der normierten Darstellung mittels erneuter Hough-Kreiserkennung detektiert werden.

Die Implementierung der Hough-Transformation durch die Bibliothek opencv-python enthält einen Parameter `minDist`. Dieser gibt den minimalen Abstand zwischen zwei erkannten Kreisen in Pixel an. Dies ist für die Erkennung der Ringsegmente einer Dartscheibe problematisch, da sich diese einen Mittelpunkt teilen, wobei sich nur die Radien unterscheiden. Da sich dieser Parameter nicht auf 0 setzen lässt ist es notwendig die Hough-Transformation ringweise auszuführen. Für jeden Ring ist ein enger Suchbereich $[r_{\min}, r_{\max}]$ definiert, der aus den bekannten Proportionen einer Dartscheibe abgeleitet wurde. Tabelle 3.1 listet die verwendeten Ringe und ihre jeweiligen Suchbereiche.

Ring	$r_{\min}$ (px)	$r_{\max}$ (px)
Bulls-Eye	0	25
Outer Bull	30	60
Inner Triple	190	230
Outer Triple	240	270
Inner Double	340	385
Outer Double	390	450

Tabelle 3.1: Suchbereiche der Hough-Kreiserkennung je Ring im normierten 1024×1024-Koordinatensystem.

Für jeden Suchbereich wird die Hough-Transformation mit einem Akkumulatorschwellwert von `param2` $= 50$ und einem Kantenschwellwert von `param1` $= 220$ ausgeführt. Der niedrigere Akkumulatorschwellwert gegenüber der initialen Scheibenerkennung ist dabei bewusst gewählt, da die Ringkanten im normierten Bild feiner und weniger dominant sind als der äußere Scheibenrand.

Liefert die Hough-Transformation mehrere Kreishypothesen innerhalb eines Suchbereichs, wird jene selektiert, deren Mittelpunkt den geringsten euklidischen Abstand zum Referenzpunkt $(512, 512)$ aufweist:

$$c^* = \arg\min_{c \in \mathcal{C}} \; (c_x - x_{\text{ref}})^2 + (c_y - y_{\text{ref}})^2 \tag{3.2}$$

wobei $\mathcal{C}$ die Menge aller erkannten Kreishypothesen im jeweiligen Suchbereich bezeichnet. Wird für einen Ring keine gültige Hypothese gefunden, so wird die weitere Verarbeitung abgebrochen, da eine vollständige Segmentierung der Dartscheibe die erfolgreiche Erkennung sämtlicher Ringe voraussetzt.

3.3.3 Lokalisierung der Segmentlinien

Zur Erkennung der radialen Segmentlinien einer Dartscheibe wird eine eigene Bildverarbeitungspipeline eingesetzt, die wieder aus drei aufeinanderfolgenden Schritten besteht: Vorverarbeitung, Kantendetektion mit anschließender HT sowie einer abschließenden Clusterung der detektierten Linien.

Dabei wurde im ersten Schritt erneut ein medianer Filter auf das Eingangsfoto angewandt um das rauschen weiter zu unterdrücken und saubere Linien erkennen zu können.

Auf dem vorverarbeiteten Bild wird anschließend der Canny-Kantendetektionsalgorithmus angewendet, wobei die Hysterese-Schwellenwerte auf 250 bzw. 300 gesetzt sind. Diese verhältnismäßig hohen Schwellenwerte bewirken, dass nur ausgeprägte, kontrastreiche Kanten extrahiert werden, was die Anzahl störender Artefakte reduziert.

Die so gewonnene Kantenkarte dient als Eingabe für die klassische HT zur Liniendetektion (cv2.HoughLines). Diese arbeitet im Parameterraum (ρ, θ), wobei ρ den senkrechten Abstand einer Linie vom Koordinatenursprung und θ deren Winkel zur horizontalen Achse beschreibt. Die Auflösung beträgt $\Delta\rho = 0,5$ Pixel und $\Delta\theta = 1°$, bei einem Abstimmungsschwellenwert von 80 Punkten.

Da auf einer Dartscheibe alle Segmentierungslinien durch den Mittelpunkt verlaufen, wird nach der Hough-Transformation ein geometrischer Filter angewendet. Für jede detektierte Linie (ρ, θ) wird der Abstand zwischen dem angegebenen ρ-Wert und dem projizierten ρ-Wert des bekannten Bildmittelpunkts $(c_x, c_y) = (512, 512)$ berechnet:

$$d = |\rho - (c_x \cdot \cos\theta + c_y \cdot \sin\theta)| \tag{3.3}$$

Linien, bei denen dieser Abstand einen Schwellenwert von 20 Pixeln überschreitet, werden als Nicht-Zentrumslinien verworfen. Dieser Schritt reduziert Fehldetektionen erheblich, da er domänenspezifisches Wissen über die Geometrie der Dartscheibe explizit in den Algorithmus einbezieht.

Die Hough-Transformation liefert typischerweise mehrere nah beieinanderliegende Liniendetektionen für eine einzige physikalische Linie. Um diese Redundanz zu eliminieren,

wird ein einfaches winkelbasiertes Clusterverfahren eingesetzt. Dabei werden alle Linien iterativ gruppiert, deren Winkel θ um weniger als 5° voneinander abweichen. Jede so gebildete Gruppe wird durch ihre mittlere Linie – d. h. den Durchschnitt aller ρ- und θ-Werte innerhalb der Gruppe – repräsentiert. Das Ergebnis ist eine bereinigte Menge eindeutiger, repräsentativer Linien, die den radialen Segmentierungslinien der Dartscheibe entsprechen.

3.3.4 Berechnung des Scores

Nachdem die Segmentierungslinien und Kreise der Dartscheibe detektiert wurden, kann aus der Position eines Dartpfeils der zugehörige Punktwert berechnet werden. Die Score-Berechnung gliedert sich in drei Schritte: Koordinatentransformation, Winkel- und Radiusbestimmung sowie die abschließende Feldzuordnung.

Um den score korrekt berechnen zu können, muss der Auftreffpunkt (x, y) aus dem Ursprungsbild zunächst mittels der gleichen homographischen Transformation, welche in Abschnitt 3.3.1 berechnet wurde, in das normierte Scheibenkoordinatensystem überführt werden. Der transformierte Punkt $p' = (p_x, p_y)$ liegt anschließend in einem quadratischen Bildraum mit dem Scheibenmittelpunkt bei $(c_x, c_y) = (512, 512)$.

Im normierten Koordinatensystem werden für den transformierten Punkt zwei geometrische Merkmale berechnet. Der Polarwinkel φ gibt die Richtung des Punktes relativ zum Scheibenmittelpunkt an und wird mittels der Arkustangens-Funktion bestimmt:

$$\varphi = \operatorname{atan2}(p_y - c_y,\ p_x - c_x) \tag{3.4}$$

Da `atan2` Werte im Bereich $(-\pi, \pi]$ liefert, wird das Ergebnis auf das Intervall $[0, 2\pi)$ normalisiert, indem bei negativen Winkeln 2π addiert wird. Der euklidische Abstand r des Punktes vom Scheibenmittelpunkt ergibt sich zu:

$$r = \sqrt{(p_x - c_x)^2 + (p_y - c_y)^2} \tag{3.5}$$

Die detektierten Hough-Linien beschreiben jeweils eine Halbgerade. Um das vollständige Winkelintervall $[0, 2\pi)$ abzudecken, wird jede Linie mit dem Winkel θ um ihre Gegenrichtung $\theta + \pi$ ergänzt. Die so gewonnenen Winkelwerte werden aufsteigend sortiert und bilden die Grenzen der 20 Winkelsegmente der Dartscheibe.

Der Winkel φ des Auftreffpunkts wird anschließend in dieser sortierten Liste verortet: Das zugehörige Segment ist dasjenige, dessen linke Grenze φ_l und rechte Grenze φ_r den Punkt einschließen, d. h.:

$$\varphi_l \leq \varphi < \varphi_r \tag{3.6}$$

Der so bestimmte Segmentindex wird mit einem empirisch ermittelten Offset von $\Delta = 6$ Positionen korrigiert, um die Abweichung zwischen der geometrischen Segmentreihenfolge und der auf der Dartscheibe aufgedruckten Zahlenbelegung auszugleichen. Der Grundwert b des Feldes ergibt sich dann aus der standardisierten Dart-Reihenfolge `DART_ORDER` als:

$$b = \texttt{DART_ORDER}\Big[(s + \Delta) \bmod 20\Big] \tag{3.7}$$

wobei s den rohen Segmentindex bezeichnet.

Anhand des Abstands r vom Scheibenmittelpunkt wird abschließend das radiale Feld bestimmt, in das der Dartpfeil eingedrungen ist. Die Radiusgrenzen der sechs konzentrischen Zonen werden aus den zuvor detektierten Kreisen der Scheibe extrahiert und aufsteigend sortiert. Tabelle 3.2 fasst die Zuordnung zusammen.

Bedingung	**Feld**	**Punktwert**
$r \leq r_{\text{Bull}}$	Bullseye (Bull's Eye)	50
$r \leq r_{\text{OuterBull}}$	Outer Bull	25
$r_{\text{Triple,i}} \leq r \leq r_{\text{Triple,o}}$	Triple-Ring	$3b$
$r_{\text{Double,i}} \leq r \leq r_{\text{Double,o}}$	Double-Ring	$2b$
$r \leq r_{\text{Double,o}}$	Einfaches Feld	b
$r > r_{\text{Double,o}}$	Außerhalb	0

Tabelle 3.2: Radiale Feldzuordnung und zugehörige Punktwerte. b bezeichnet den Grundwert des getroffenen Winkelsegments.

Der finale Punktwert ergibt sich damit eindeutig aus der Kombination des Winkelsegments und der radialen Zone des Auftreffpunkts.

Die Abbildung 3.2 visualisiert die Berechnung des Scores eines Punktes P

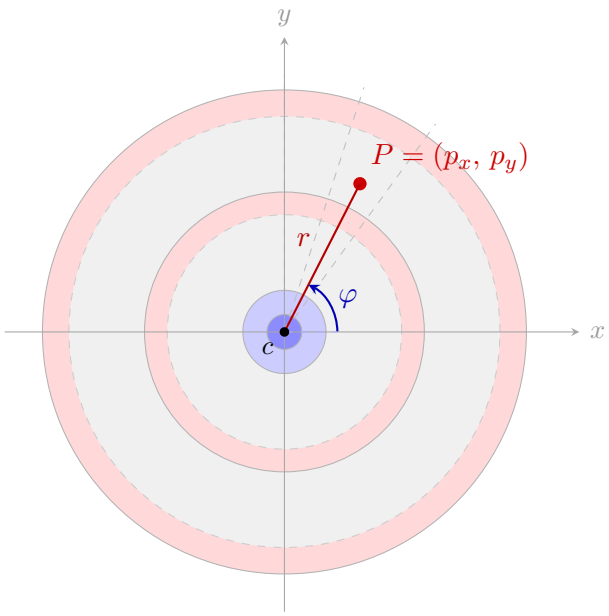

Abbildung 3.2: Geometrische Grundlage der Score-Berechnung im normierten Scheibenkoordinatensystem. Der Auftreffpunkt P wird durch den Polarwinkel φ und den Radius r eindeutig einem Winkelsegment sowie einer radialen Wertungszone zugeordnet.

3.4 Evaluation

Im Folgenden wird festgelegt, wie die in der Leitfrage formulierten Vergleichskriterien im Rahmen dieser Arbeit konkret gemessen werden.

Erkennungsgenauigkeit

Die Erkennungsgenauigkeit beider Ansätze wird anhand der mittleren IoU (mean IoU, mIoU) über alle Testbilder bewertet. Zusätzlich wird die Erkennungsrate als Anteil der Bilder ausgewiesen, bei denen ein IoU-Schwellwert von IoU $\geq 0{,}5$ erreicht wird [Eve+10]. Als Referenz dienen Binärmasken, die durch manuelle Annotation mithilfe des Polygon-Werkzeugs der Annotationsplattform [Rob24] erstellt wurden und die Kontur der Dartscheibe näherungsweise beschreiben. Da beide Ansätze dieselbe nachgelagerte Segmentierungs- und Punktberechnungslogik verwenden, sind Unterschiede in der mIoU ausschließlich auf die jeweilige Lokalisierungsmethode zurückzuführen, was einen isolierten Vergleich beider Ansätze unter sonst identischen Bedingungen ermöglicht.

Robustheit gegenüger Aufnahmebedingungen

Zur Bewertung der Robustheit wird der Testdatensatz in Untergruppen eingeteilt, die jeweils eine spezifische Störbedingung repräsentieren. Untersucht werden Lichtverhältnisse (Über- und Unterbelichtung), Perspektivverzerrung (flache Aufnahmewinkel) sowie Skalierung (variierender Bildausschnitt). Die mIoU wird pro Untergruppe separat ausgewertet, um zu identifizieren, unter welchen Bedingungen die jeweilige Methode am stärksten beeinträchtigt wird [Sze22].

Verarbeitungsgeschwindigkeit

Die Verarbeitungsgeschwindigkeit wird als mittlere Inferenzzeit in Millisekunden pro Bild bestimmt und umfasst die vollständige Verarbeitungspipeline vom Eingabebild bis zur Erzeugung der resultierenden Maske. Die Experimente wurden auf einem Acer Aspire-13 Laptop mit einem Intel Core i5-1235U Prozessor der 12. Generation, 32 GB Arbeitsspeicher sowie dem Betriebssystem Windows-11 durchgeführt.

Die Ausführung erfolgte CPU-basiert unter Verwendung von Python 3.11 und PyTorch 2.10. Zur Reduktion zufälliger Schwankungen wird für jedes Bild der Mittelwert über mindestens 50 Wiederholungen berechnet.

Implementierungsaufwand

Der Implementierungsaufwand wird qualitativ bewertet und umfasst den Aufwand zur Datenbeschaffung und -annotation, den Trainingsaufwand des U-Net-Modells sowie den Integrationsaufwand in eine mobile Anwendung. Da dieser Aspekt einer quantitativen Messung nicht zugänglich ist, wird er anhand einer strukturierten Beschreibung der jeweiligen Entwicklungsschritte dokumentiert und verglichen.

4 Design und Implementierung

Dieses Kapitel beschreibt die konkrete Umsetzung der in Kapitel 3 vorgestellten Ansätze. Im Vordergrund stehen dabei die getroffenen Designentscheidungen sowie die Begründung der gewählten Parameter und Implementierungsstrategien. Darüber hinaus werden verworfene Alternativen und Fehlschläge dokumentiert, um die Entwicklung der finalen Lösung nachvollziehbar zu machen.

Die Implementierung gliedert sich in drei Teile: den algorithmischen Ansatz auf Basis von Canny-Kantenerkennung und Hough-Transformation, den KI-basierten Ansatz mittels U-Net sowie die gemeinsamen Verarbeitungsschritte zur Feldsegmentierung und Punktberechnung, welche beiden Pipelines zugrunde liegen.

4.1 Algorithmischer Ansatz

4.1.1 Vorverarbeitung

Als erster Verarbeitungsschritt wird das Eingabebild mit einem Median-Filter geglättet, um Rauschen zu reduzieren. Der Median-Filter wurde dem Gaußschen Weichzeichner vorgezogen, da er Salz-und-Pfeffer-Rauschen effektiv unterdrückt und dabei Kanten schärfer erhält [Ope25]. Dies ist für die nachfolgende Kantendetektion von besonderer Bedeutung, da verwischte Kanten die Erkennungsgenauigkeit der Hough-Transformation beeinträchtigen. Die Kernelgröße von $k = 11$ wurde empirisch ermittelt, da kleinere Werte nicht ausreichend glätten und größere Werte zu stark verwischen. Bei kleineren k wurden durch übermäßiges Rauschen zahlreiche falsche Kreishypothesen generiert, während größere k die Kanten der Dartscheibe zu stark verwischten, was ebenfalls zu unzuverlässigen Erkennungsergebnissen führte.

Ergänzend zur Graustufekonvertierung wurde die Methode nach Otsu [Ots79] als alternatives Binarisierungsverfahren untersucht. Die Otsu-Methode bestimmt den optimalen Schwellwert vollautomatisch, indem sie die Varianz zwischen den resultierenden Klassen – Vordergrund und Hintergrund – maximiert und dabei ausschließlich auf dem Grauwerthistogramm des Bildes operiert [Ots79]. Gegenüber der einfachen Graustufenkonvertierung bietet die direkte Schwellwertbildung im Grauwertbild jedoch keinen wesentlichen Vorteil,

da beide Verfahren keinerlei Farbinformation nutzen und somit gleichermaßen anfällig gegenüber wechselnden Lichtverhältnissen und farblich heterogenen Hintergründen sind. Die einfache Graustufenkonvertierung erwies sich dabei als ausreichend und wurde aufgrund ihrer geringeren Komplexität bevorzugt.

4.1.2 Erkennung der Dartscheibe

Der Ansatz mit variierenden Suchradien wurde gewählt, um die Erkennung von Dartscheiben unterschiedlicher Größe zu ermöglichen. Da die Scheibengröße im Bild je nach Aufnahmeabstand variiert, ist es notwendig, die Hough-Transformation mit einem Bereich von Radien zu betreiben, um sowohl kleine als auch große Scheiben zuverlässig zu erkennen.

Da die Funktion $cv2.HoughCircles$ standardmäßig eine Liste von erkannten Kreisen liefert [Ope] wird hier immer der kleinste genommen. Das liegt daran, dass viele Dartscheiben mit einem äußeren Schutzring versehen sind, dessen Radius den der eigentlichen Scheibe übersteigt.

Dieser Ansatz setzt voraus, dass die Kamera annähernd frontal auf die Dartscheibe gerichtet ist. Da die Quellpunkte aus der achsenparallelen Begrenzungsbox des erkannten Kreises abgeleitet werden, enthält die berechnete Homographie keine Information über die tatsächliche räumliche Orientierung der Scheibe. Bei stärkerer perspektivischer Verzerrung führt dies zu einer unvollständigen Entzerrung, was die Zuverlässigkeit der nachgelagerten Feldsegmentierung beeinträchtigt. Diese Einschränkung motiviert den in Kapitel 3.2 beschriebenen Machine-Learning-Ansatz, der eine robustere Grundlage für die perspektivische Korrektur bietet.

4.2 Machine Learning Ansatz

4.2.1 Erkennung der Dartscheibe

4.2.2 Nachverarbeitung der Maske

4.3 Gemeinsame Verarbeitungsschritte

4.3.1 Perspektivische Korrektur und Normalisierung

Ziel dieser Normalisierung ist es, die anschließende geometrische Feldsegmentierung unabhängig von Aufnahmeabstand und Bildauflösung zu gestalten. Die Auflösung im Zielraum ist dabei frei wählbar und wurde empirisch auf 1024×1024 Pixel festgelegt. Ein zu gering gewählter Wert resultiert in einer unzureichenden Auflösung der Segmentlinien und beeinträchtigt damit die Genauigkeit der Punktberechnung. Ein zu hoch gewählter Wert hingegen erhöht den Rechenaufwand, ohne eine signifikante Verbesserung der Erkennungsgenauigkeit zu bewirken, da die zusätzlichen Pixel vorwiegend Rauschen enthalten.

4.3.2 Lokalisierung der Ringe

4.3.3 Lokalisierung der Segmentlinien

4.3.4 Berechnung des Scores

5 Ergebnisse

6 Fazit und Ausblick

Literatur

[Can86] John Canny. „A Computational Approach to Edge Detection“. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* PAMI-8.6 (Nov. 1986), S. 679–698. ISSN: 1939-3539. DOI: 10.1109/TPAMI.1986.4767851. URL: https://ieeexplore.ieee.org/abstract/document/4767851 (besucht am 27. 11. 2025).

[DH72] Richard O. Duda und Peter E. Hart. „Use of the Hough transformation to detect lines and curves in pictures“. In: *Commun. ACM* 15.1 (Jan. 1972), S. 11–15. ISSN: 0001-0782. DOI: 10.1145/361237.361242. URL: https://dl.acm.org/doi/10.1145/361237.361242 (besucht am 06. 04. 2026).

[Eve+10] Mark Everingham u. a. „The PASCAL Visual Object Classes (VOC) Challenge“. In: *International Journal of Computer Vision* 88.2 (2010), S. 303–338. URL: https://link.springer.com/article/10.1007/s11263-009-0275-4.

[GBC16] Ian Goodfellow, Yoshua Bengio und Aaron Courville. *Deep Learning*. http://www.deeplearningbook.org. MIT Press, 2016.

[Hou62] F V C Hough. „METHOD AND MEANS FOR RECOGNIZING COMPLEX PATTERNS“. en. In: (1962).

[IK88] J. Illingworth und J. Kittler. „A survey of the hough transform“. In: *Computer Vision, Graphics, and Image Processing* 44.1 (Okt. 1988), S. 87–116. ISSN: 0734-189X. DOI: 10.1016/S0734-189X(88)80033-1. URL: https://www.sciencedirect.com/science/article/pii/S0734189X88800331 (besucht am 30. 03. 2026).

[Ope] OpenCV. *OpenCV: Image Processing (imgproc module)*. URL: https://docs.opencv.org/3.4/d7/da8/tutorial_table_of_content_imgproc.html (besucht am 06. 04. 2026).

[Ope25] OpenCV. *OpenCV: Smoothing Images*. Juli 2025. URL: https://docs.opencv.org/3.4/d4/d13/tutorial_py_filtering.html (besucht am 25. 04. 2026).

[Ope26] OpenCV. *Basic concepts of the homography explained with code*. 2026. URL: https://docs.opencv.org/4.x/d9/dab/tutorial_homography.html (besucht am 14. 03. 2026).

[Ots79] Nobuyuki Otsu. „A Threshold Selection Method from Gray-Level Histograms“. In: *IEEE Transactions on Systems, Man, and Cybernetics* 9.1 (1979), S. 62–66. DOI: 10.1109/TSMC.1979.4310076.

[Rob24] Roboflow Inc. *Roboflow Annotate: Image Annotation Tool*. https://docs.roboflow.com/annotate. Abgerufen am 03.05.2026. 2024.

[Sze22] Richard Szeliski. *Computer Vision: Algorithms and Applications*. en. Texts in Computer Science. Cham: Springer International Publishing, 2022. ISBN: 978-3-030-34371-2 978-3-030-34372-9. DOI: 10.1007/978-3-030-34372-9. URL: https://link.springer.com/10.1007/978-3-030-34372-9 (besucht am 27. 11. 2025).

Anhang

Hier ist etwas für den Anhang.